

**Меня хорошо видно
& слышно?**



LLM-инженер

Двухуровневая гибридная рекомендательная система
семантического поиска развернутая на базе NVIDIA Triton
Inference Server и векторной СУБД Qdrant



Защита проекта

Тема: *Двухуровневая гибридная рекомендательная система семантического поиска развернутая на базе NVIDIA Triton Inference Server и векторной СУБД Qdrant*



Филатов Алексей

РСХБ-Автоматизация

План защиты

Цель и задачи проекта

Какие технологии использовались

Что получилось

Выводы

Вопросы и рекомендации

Цель и задачи проекта

Цель проекта: Разработать и развернуть высокопроизводительную двухуровневую гибридную рекомендательную систему семантического поиска на базе промышленного стека **NVIDIA Triton Inference Server**, векторной СУБД **Qdrant** и контура наблюдаемости **Langfuse LLMops**.

Задачи проекта :

1. **Проектирование Clean Architecture:** Описать доменную логику, интерфейсы и графовый NLP-пайплайн Агента на базе DIP-инверсии зависимостей.
2. **Оптимизация и C++ инференс нейросетей:** Экспортировать и развернуть каскад из ML-моделей в репозитории **NVIDIA Triton Server** с поддержкой вычислений на **GPU (CUDA)**.
3. **Аппаратное векторное индексирование:** Создать многовекторную коллекцию в **Qdrant DB** и реализовать предфильтрацию метаданных (Metadata Pre-Filtering) с помощью морфологического контура **spaCy**.
4. **Разработка гибридного RecSys-движка:** Интегрировать многофакторную формулу ранжирования (Linear Score Fusion), учитывающую ценовые сегменты, ALS-историю, коммерческий бустинг (Commercial Boosting) и политику «холодного старта».
5. **Внедрение сквозного мониторинга:** Развернуть контур скрейпинга аппаратных C++ метрик Тритона через **Prometheus** и настроить аналитические панели в **Grafana**.



Технологический стек и подходы к разработке

1. NVIDIA Triton Inference Server & TensorRT

Зачем: Выделенный C++ сервер для изолированного исполнения тяжелых нейросетевых моделей (MiniLM, BGE, PaliGemma) на GPU (CUDA) отдельно от Python-кода приложения.

Впечатление: Мощное Enterprise-решение. Динамический батчинг и параллельное выполнение моделей на GPU обеспечили колоссальную пропускную способность в **413.5 RPS** при Latency инференса всего в **4.4 мс**.

2. Векторная СУБД Qdrant

Зачем: Хранение 384-мерных семантических векторов каталога товаров и аппаратный gRPC-поиск кандидатов по косинусному сходству.

Впечатление: Исключительно быстрая C++ база данных. Механизм *Metadata Pre-Filtering* позволил отсекавать нерелевантные категории товаров на уровне поискового движка СУБД еще до векторного сравнения

3. Платформа Langfuse LLMops & Фреймворк RAGAS

Зачем: Сквозной трейсинг графа ИИ-Агента и автоматическая оценка качества поиска по методологии *LLM-as-a-Judge*.

Впечатление: Лучший инструмент для контроля качества ИИ. Интеграция позволила в реальном времени отслеживать метрики RAGAS (*Faithfulness, Answer Relevancy*), выявлять галлюцинации моделей и визуализировать логику Агента на удобных дашбордах.


4. Prometheus & Grafana

Зачем: Сбор прикладных и аппаратных C++ метрик с Тритона на порту 8002 и их визуализация.

Впечатление: Стандарт для Production. Позволяет наглядно увидеть стабильную полку утилизации GPU и Latency под стресс-нагрузкой, что необходимо для мониторинга стабильности ИИ-систем.



Архитектура проекта



RecSys

```
2026-10-07 10:23:48 - [INFO] - 🎨 [Orchestrator] Декларативный графовый NLP-пайплайн и Рекомендательный Сервис успешно
развернуты.
sh: 1: lsof: not found
* Running on local URL: http://0.0.0.0:7860 ↗
* To create a public link, set `share=True` in `launch()`.
2026-10-07 13:24:43 - [INFO] - 🚀 [spaCy Контур] В CLIP улетает чистое семантическое ядро: 'искать тёплый холодный зима'
2026-10-07 13:24:43 - [INFO] - 🔍 [gRPC Отладка -> paraphrase_embedder] input_ids: (1, 128), mask: (1, 128), token_type_ids:
(1, 128)
2026-10-07 13:24:43 - [INFO] - 🏗️ [Workflow] Вызов Шаг 5: Нейросетевое Cross-Attention переранжирование...
2026-10-07 13:24:44 - [INFO] - 🏗️ [RecSys Stage 2] User: new_user_cold_start | Зимняя чер... | Search: 0.78 | ALS: 0.50 |
Segment: 0.50 | Boost: 1.3 | Итор: 0.7325
2026-10-07 13:24:44 - [INFO] - 🏗️ [RecSys Stage 2] User: new_user_cold_start | Спортивный... | Search: 0.97 | ALS: 0.50 |
Segment: 0.50 | Boost: 1.0 | Итор: 0.6391
2026-10-07 13:24:44 - [INFO] - 🏗️ [RecSys Stage 2] User: new_user_cold_start | Классическ... | Search: 0.06 | ALS: 0.50 |
Segment: 0.50 | Boost: 1.0 | Итор: 0.2734
2026-10-07 13:24:44 - [INFO] - 🏗️ [RecSys Stage 2] User: new_user_cold_start | Теплый сер... | Search: 0.27 | ALS: 0.50 |
Segment: 0.50 | Boost: 1.0 | Итор: 0.3600
2026-10-07 13:24:44 - [INFO] - 🏗️ [RecSys Stage 2] User: new_user_cold_start | Красные сп... | Search: 0.00 | ALS: 0.50 |
Segment: 0.50 | Boost: 1.0 | Итор: 0.2500
2026-10-07 13:24:44 - [INFO] - ✅ Пайплайн успешно отработал за 782.33 мс
```

Gradio client browser

 **Мультимодальный Omni-Поисковик E-Corp (Declarative Neural-Symbolic Architecture)**

Текстовый запрос покупателя

я ищу что-то теплое для холодной зимы



🎵 Голосовой поиск (Whisper ASR)



Перетащите аудио сюда

- или -

Нажмите для загрузки



 Запустить Сквозной Пайплайн

Аналитика и ответ ИИ-Агента



🕒 Время сквозного инференса (RTT Latency): 782.33 мс



 ФИНАЛЬНЫЙ ОТВЕТ ИИ-АГЕНТА E-CORP:

Пронализировав ваш запрос и историю нашего диалога, я настоятельно рекомендую обратить внимание на товар 'Зимняя черная кожаная куртка с мехом' по цене 18900 руб. Этот выбор идеально соответствует вашему контексту, так как содержит ключевые свойства и теги: [куртка, черный, кожа, зима, мех]. Натуральные материалы обеспечат максимальный комфорт и защиту в нужный сезон.

=====



 ТЕХНИЧЕСКИЕ МЕТАДАННЫЕ ВЫПОЛНЕНИЯ ПАЙПЛАЙНА:



Вычисленное ИИ-Намерение (Intent): 'PRODUCT_SEARCH'



Обогащенное семантическое ядро (Теги для CLIP): 'искать тёплый холодный зима'



Извлеченные из Odrant DB сырые кандидаты:

- ```

{'name': 'Зимняя черная кожаная куртка с мехом', 'price': 18900, 'tags': 'куртка, черный, кожа, зима, мех', 'image_file': 'black_jacket.jpg', 'qdrant_score': 0.7871}
{'name': 'Спортивный желтый дождевик водонепроницаемый', 'price': 5500, 'tags': 'куртка, желтый, спорт, дождевик', 'image_file': 'yellow_raincoat.jpg', 'qdrant_score': 0.7762}
{'name': 'Классические белые кожаные кеды', 'price': 6200, 'tags': 'обувь, кеды, белый, кожа', 'image_file': 'white_shoes.jpg', 'qdrant_score': 0.6500}
{'name': 'Теплый серый свитер крупной вязки', 'price': 4800, 'tags': 'свитер, серый, шерсть, тепло', 'image_file': 'gray_sweater.jpg', 'qdrant_score': 0.6376}
{'name': 'Красные спортивные беговые кроссовки', 'price': 7800, 'tags': 'обувь, кроссовки, красный, спорт', 'image_file': 'red_sneakers.jpg', 'qdrant_score': 0.6265}


```



 Рекомендуемый товар из каталога E-Corp



# Dashboard Grafana



# Langfuse Ragas Scores

## Scores<sup>i</sup>

 Filter

 24 hours 

| Trace           | O... | T... |  Timestamp ▼ | Source | Name                    | Data Type | Value  |
|-----------------|------|------|-----------------------------------------------------------------------------------------------|--------|-------------------------|-----------|--------|
| 60064d8d-1e6... |      |      | 07.10.2026, 13:27:17                                                                          | API    | ragas_context_precision | NUMERIC   | 1      |
| 60064d8d-1e6... |      |      | 07.10.2026, 13:27:17                                                                          | API    | ragas_answer_relevancy  | NUMERIC   | 0.9200 |
| 60064d8d-1e6... |      |      | 07.10.2026, 13:27:17                                                                          | API    | ragas_faithfulness      | NUMERIC   | 0.9500 |



# Выводы

## 1. Достижение цели и выполнение задач:

**Цель полностью достигнута.** Создана и развернута высокопроизводительная двухуровневая система семантического поиска. Инженерные задачи (от проектирования *Clean Architecture* до интеграции *Langfuse/Ragas*) выполнены в полном объеме. Контур стабилен и верифицирован.

## 2. Что далось легко, а где возникли трудности:

- *Легко:* Проектирование модулей бизнес-логики, кастомного рекомендера (*RecSys движка*) и декларативного графового пайплайна на Python благодаря строгому следованию принципам *Clean Architecture*.
- *Трудно:* Инфраструктурная стыковка компонентов в Docker. Наибольших усилий потребовала правильная отладка проброса аппаратных CUDA-драйверов NVIDIA внутрь изолированных контейнеров Gradio и Тритона, а также устранение скрытых нестыковок в сетевых gRPC/HTTP сокетах и версиях внешних библиотек

## 3. Временные затраты:

Проект занял **около 3–4 недель** интенсивной MLOps-инженерии (включая этапы конвертации моделей в ONNX/TensorRT, наполнения векторной СУБД, верстки UI и настройки сквозного мониторинга Grafana/Prometheus).



#### 4. Полезность проекта (Оценка: 10 / 10):

**10 — Исключительно полезно.** Получен уникальный прикладной опыт построения *Production-ready RAG-систем* промышленного уровня. Проект позволил выйти за рамки стандартных Python-скриптов и освоить оркестрацию распределенного ИИ на GPU, работу с C++ серверами инференса и методологию автоматизированного судейства *LLM-as-a-Judge*.

#### 5. План дальнейшего развития:

Планируется масштабировать проект: перенести Docker Compose стек в оркестратор **Kubernetes (K8s)** с использованием *NVIDIA GPU Operator* для обеспечения автоскалирования под нагрузкой. Также в планах заменить тестовые текстовые датасеты на полноценный мультимодальный поиск (интеграция VLM-моделей *PaliGemma* для сквозного семантического анализа изображений одежды по пикселям).

# Вопросы и рекомендации



если есть вопросы



если вопросов нет

**Спасибо за внимание!**



